

Laboratorio 1. Análisis Exploratorio, PCA y Apriori

INSTRUCCIONES:

Utilice el data set [House Prices: Advanced Regression Techniques](#) que comparte Kaggle. Debe hacer un análisis exploratorio para entender mejor los datos, sabiendo que el objetivo final es predecir los precios de las casas. Recuerde explicar bien cada uno de los hallazgos que haga. La forma más organizada de hacer un análisis exploratorio es generando ciertas preguntas de las líneas que le parece interesante investigar. Genere un informe en pdf con las explicaciones de los pasos que llevó a cabo y los resultados obtenidos. Recuerde que la investigación debe ser reproducible por lo que debe guardar el código que ha utilizado para resolver los ejercicios y/o cada uno de los pasos llevados a cabo si utiliza una herramienta visual. Lleve a cabo un análisis de componentes principales. Este laboratorio debe realizarse en **PAREJAS**. Para que se pueda calificar su laboratorio debe estar inscrito en algún grupo de canvas.

DESCRIPCIÓN DEL DATASET

El dataset contiene datos de 1460 casas en Ames, Iowa y 79 variables que describen prácticamente todos los aspectos de estas. El archivo de descripción de los datos, que incluye nombre de variables y posibles valores lo puede encontrar en el link siguiente: <https://www.kaggle.com/c/house-prices-advanced-regression-techniques/data>

EJERCICIOS

1. Haga una exploración rápida de sus datos para eso haga un resumen de su dataset.
2. Diga el tipo de cada una de las variables del dataset (cualitativa o categórica, cuantitativa continua, cuantitativa discreta)
3. Incluya los gráficos exploratorios siendo consecuentes con el tipo de variable que están representando.
4. Aísle las variables numéricas de las categóricas, haga un análisis de correlación entre las mismas.
5. Utilice las variables categóricas, haga tablas de frecuencia, proporción, gráficas de barras o cualquier otra técnica que le permita explorar los datos
6. Estudie si es conveniente hacer un Análisis de Componentes Principales. Recuerde que puede usar el índice KMO y el test de esfericidad de Bartlett. Haga un análisis de componentes principales con las variables numéricas, discuta los resultados e interprete los componentes.
7. Obtenga reglas de asociación interesantes del dataset. Discuta sobre el nivel de confianza y soporte.

EVALUACIÓN

NOTA: La evaluación de cada integrante del grupo será de acuerdo con sus contribuciones al trabajo grupal

(42 puntos) Análisis Exploratorio:

- Estudia las variables cuantitativas mediante técnicas de estadística descriptiva

- Hace gráficos exploratorios como histogramas, diagramas de cajas y bigotes, gráficos de dispersión que ayudan a explicar los datos
- Analiza las correlaciones entre las variables, trata de explicar los outliers (puntos atípicos) y toma decisiones acertadas ante la presencia de valores faltantes.
- Estudia las variables categóricas
- Elabora gráficos de barra, tablas de frecuencia y de proporciones
- Elabora gráficos adecuados según el tipo de dato que representan
- Explica muy bien todos los procedimientos y los hallazgos que va haciendo.

(18 puntos) Análisis de componentes Principales

- Estudia la matriz de correlación, la agrega y explica lo que observa en ella
- Determina si es posible usar la técnica de análisis factorial para hallar las componentes principales
- Determina si vale la pena aplicar las componentes principales interpretando el test de esfericidad de Bartlett
- Obtiene los componentes principales y explica cuántos seleccionará para explicar la mayor variabilidad posible.
- Interpreta los coeficientes principales.

(18 puntos) Reglas de asociación

- Construye reglas de asociación usando el algoritmo a priori.
- Discute sobre las reglas de asociación más interesantes teniendo en cuenta sus niveles de confianza y soporte.

(22 puntos) Hallazgos y conclusiones.

- Hace un resumen de los hallazgos en el análisis exploratorio
- Llega a conclusiones sobre el análisis de componentes principales
- Determina las reglas de asociación más interesantes.

MATERIAL A ENTREGAR

- Archivo .pdf con el informe de análisis exploratorio.
- Link de Google drive donde trabajó el grupo.
- Script de R (.r o .rmd) o de Python que utilizó para responder las preguntas con el código utilizado o archivo de flujo de trabajo de KNime
- Link de github o el versionador que se utilizó.